Neuro-Loop 数据模型 v2
参考研究、取舍与实施计划

把"一个人怎样从看懂到想起、再到考场里做得出来"拆成可以存储、可以测量、可以重建的结构。

版本 v2.0 · 2026-11-10 · 面向：项目负责人审阅 · 依据：现有 `neuro-loop` 代码与 `%USERPROFILE%\.dsh\neuro-loop\` 的真实事件流
性质：研究综述 + 结构提案。文中"借鉴"与"创新"分别标注，不把已有一切说成原创。

---

0. 摘要

现有系统（v1）解决了"看得见"：星图、分层、启动序列、事件流、跨会话信箱。但它回答不了三个问题： 一道题**为什么**被判为会、**多快**能想起来、以及**明天**该复习哪一条。 v1 的数据结构只有"考点 → 命中/失误计数"，缺少题目、方法、时间三个维度，因此再好看也只是仪表盘。

本提案给出四层、五实体、六个不变量与四个算法。核心是三条判断：

1. **原子是"一次判定"，不是一道题。**同题在不同模式（认出 / 重推 / 实做）下是不同的证据。
2. **方法（method）必须是一等公民。**它是跨章节的可迁移程序，也是我们所说"记忆向量"的可操作定义： 方法 = 在考点空间上的稀疏权重 + 可复述的判据。
3. **"KV cache"应当被真的实现成一层带衰减的缓存，**而不是比喻。命中走缓存（快、易假阳性），未命中走重推（慢、更可靠），两者都记时间。

与已有系统的关系：教育测量（BKT、IRT、知识空间）提供*掌握度与判分*；间隔重复（SM-2、FSRS）提供*调度*； LLM 训练与推理（MLA、KV cache、稀疏注意力、MoE、RLHF）提供*压缩*、*命中*、*稀疏与遗忘*的工程隐喻； 智能体记忆（MemGPT、Zep/Graphiti、Mem0、HippoRAG）提供*分层存储与多跳检索*的实现先例。 本方案的创新点在于**把四者拼在一个可被单人承受的数据量上**，而不是发明新算法。

1. 原构想的形式化

1.1 四层与一次考试的过程

原文章把学习过程映射为大模型的训练与推理。落到数据上，一次"考试"其实是：



四个可测量的量由此产生：**命中率**（考点是否被想起）、**准确率**（想起后是否做对）、 **还原时间**（从想起到写出步骤耗时）、**压缩率**（方法判据字数 / 完整步骤字数）。

1.2 v1 缺什么

能力	v1 现状	后果
题目作为实体	不存在；只有考点计数	无法回答"这类题我做过几道、错在同一处吗"
方法作为实体	有 10 张卡，但未接入判定与调度	方法无法被复习，也无法解释"为什么这题该用这个"
时间维度	只有 `dueAt`，无耗时	"想得起来但很慢"无法与"想不起来"区分
缓存层	无	"熟题秒出"与"现场推导"没有分别记录，假阳性无法被识别
稀疏性	考点图接近全连接（每科 16 条边 / 11 节点）	检索没有取舍，等于没有注意力

2. 先例地图

下列条目只保留对"单人、无标注数据、需要可解释"这一约束真正有用的部分。表中"借鉴"一栏写我们打算拿什么。

2.1 教育测量与知识追踪

先例	年份	机制（一句）	借鉴	局限
BKT（Bayesian Knowledge Tracing）	1995	每个知识点四个参数（已会/学会/失误/猜对），贝叶斯更新掌握概率	掌握度可解释、参数少	假设知识点独立，忽略方法层
知识空间理论 / ALEKS	1985–	用"会 A 才能学 B"的前置关系定义可达知识状态	前置边与"外 frontier"概念	建图成本高，需专家
IRT	1960s–	能力 θ 与题目难度/区分度建模答对概率	难度可分、可做冷启动	需大量作答标定题目参数
Elo / Duolingo 用法	2010s	能力与题目同尺度，在线更新	单人也可更新（无群体数据）	只给单一数值，无遗忘
DKT / DKVMN / SAKT / AKT	2015–2020	用序列模型预测下一次作答	序列即证据、可迁移	需千级学生数据；不可解释
Q-matrix	1990s–	题目 × 知识点的 0/1 关联矩阵	题目-考点稀疏关联	多标签时矩阵病态
pyKT	2022	知识追踪开源工具箱（多模型统一评测）	评测口径与基线	面向数据集，不面向个人

2.2 间隔重复与记忆模型

先例	年份	机制	借鉴	局限
SM-2（SuperMemo）	1987	按回忆质量 0–5 调整间隔（EF 因子）	极简、可手算	参数固定，不分难度
Anki / FSRS	2022–	每卡 (stability, difficulty)，用记忆曲线拟合真实复习日志	单人可拟合、可解释	需要足够日志才有意义
Half-Life Regression（Duolingo）	2016	用半衰期回归预测遗忘概率	半衰期作为字段	需群体数据训练
Ebisu	2017	贝叶斯式记忆强度估计	小样本下的不确定性	实现复杂

2.3 大模型：训练与推理里可迁移的机制

机制	出处	可迁移点	误用风险
MLA（多头潜在注意力）	DeepSeek-V2	热层只存语义潜码：每 token 每层 576 维，MHA 需 32768 维（KV −93.3%，吞吐 ×5.76）；方法卡即压缩表示	压缩过度会丢判据，只剩口号；潜码不可当证据
KV cache	vLLM PagedAttention 2023	块表寻址 + 前缀共享：碎片 60–80%→<4%，吞吐 ×2–4；命中=读现成状态，未命中=整段重算	缓存不失效 = 拿旧结论答新题；失效要按块
稀疏注意力（NSA / Longformer / BigBird）	2025 / 2020	每个题目只连少量考点与方法（top-k）	连太少会漏掉跨章迁移
MoE 稀疏激活	DeepSeek-V3 2024	671B 总参 / 37B 激活，256 专家取 8；按学科路由，但每科设最低配额	路由塌缩（永远激活同一批）= 没分科
RLHF / DPO	InstructGPT / DPO	用偏好信号（对/半/错）而非正确答案调权重	偏好噪声会被放大
EWC / 灾难性遗忘	PNAS 2017	旧知识不能被新章节冲掉：复习调度兼作正则	过度保护会学不动新章

2.4 智能体记忆与检索架构

系统	机制	可取之处	局限
MemGPT / Letta	core / recall / archival 三层，主动换页	分层与"上下文预算"意识	依赖 LLM 运行时，离线不可用
Zep / Graphiti	时序知识图谱，边带有效区间（双时间轴）	事实有有效期，可回看"当时"	图数据库重，个人项目过度
Mem0	抽取→合并→更新的记忆层	去重与冲突合并策略	黑箱抽取，难解释
HippoRAG	实体索引 + Personalized PageRank 多跳	"由一个点想到另一个点"的检索	需要较完整的图
GraphRAG (2024)	Leiden 层次社区 + 每社区 LLM 摘要，map-reduce 答全局问题	先粗后细；适合"这学期学了什么"	索引成本按 chunk×LLM 计
A-MEM (2025)	Zettelkasten 卡片 + 写入即建链 + 新卡片回改邻居	写入即建立关联，不靠事后整理	无全局一致性，会漂移

3. 取舍：借鉴什么，明确不做什么

取	理由	舍	理由
BKT 式掌握概率 + FSRS 式 (stability, difficulty)	参数少、可解释、单人可跑	DKT 类深度模型	需要千级学生数据，且不可解释
Q-matrix 的稀疏关联（每题 2–4 考点）	强制取舍，才谈得上注意力	全连接知识图谱	"漂亮但没用"：任何两点都有边等于没有边
KV cache 的真实实现（命中/未命中/淘汰）	把"熟"与"会推"分开测量	把缓存当装饰性比喻	无法验证，也无法产生假阳性信号
双时间轴（记录何时学、何时有效）	回看"当时会不会"	独立图数据库	单人数据量用 JSONL 足够
事件溯源 + 可重建投影	已有实现、可审计、可回滚	直接以投影为真源	投影损坏即数据丢失

4. 提案：CNS v2（Cognitive Node Schema）

> **一句话**：把"会一道题"拆成四个可分别记录的事实——*哪些考点（稀疏 2–4 个）*、*用了哪个方法（1–3 个）*、*是想起还是重推（mode）*、*花了多久（durationMs）*；掌握度、到期、缓存全部由这些事实算出，不单独存。

4.1 五个实体

```
concept   考点：学科内的最小可判定单位
  { id, subject, block, name, prereq[], core, traps[], methodHint[] }

method    方法：跨章节的可迁移程序（本项目称"记忆向量"）
  { id, claim(≤40字), judge(何时用), steps[], instances[], traps[],
    concepts{conceptId: weight 0..1}, signature[], stability, difficulty,
    source: self|ai, verified: bool, compression }

problem   题目：一次具体任务
  { id, source, ref(文本/照片路径), concepts[{id,w}], methods[{id,w}],
    difficulty, answerRef }

attempt   一次判定（事件，append-only）
  { id, at, problem, mode: recall|recon|solve, outcome: hit|partial|miss|fp,
    durationMs, hintLevel 0..2, note }

cache     缓存项（派生，可重建）
  { key(problem指纹), problem, stepsRef, hits, lastHitAt, ttlSec, state: fresh|stale }
```

4.2 六个不变量

1. **单一真源**：只有 `attempt`（及少量内容写操作）是事实；掌握度、缓存、到期全是投影，删掉必须能重建。
2. **稀疏上限**：任一 problem 的 `concepts` ≤ 4、`methods` ≤ 3；超出即视为"这题该拆"。
3. **方法必须有判据**：`claim` 与 `judge` 不得为空；只有名字的方法不算方法。
4. **命中与准确分离**：任何聚合指标不得把 `recall` 与 `solve` 混算为一个"掌握度"。
5. **假阳性是查询**：不落字段。定义为"该考点/方法 hit 率高、但 solve 准确率低且错因重复"。
6. **时间可解释**：`durationMs` 必须记；没有时间的"会"等于没有测。

4.3 稀疏检索与打分

```
score(problem, concept) = w(problem→concept) × mastery(concept)
mastery(c) = σ( (hits - λ·misses) / (hits + misses + 1) ) × decay(Δt; stability(c))
decode(problem):  top-k concepts (k≤4) → top-m methods (m≤3)
若 cache[fp(problem)] 为 fresh → 走缓存，记 mode=recall, durationMs=命中耗时
否则 → 重推，记 mode=recon, durationMs=完整耗时；完成后回写 cache
```

λ 是"错误惩罚"，初始取 1.5；它直接对应 RLHF 里的负样本权重思想，但我们不用梯度，只用可解释的计数衰减。

4.4 缓存淘汰与假阳性

```
ttl(fp) = base × stability(method*)        base≈3 天
命中且 solve 判对  → hits+1, stability×1.35 (上限 60 天)
命中但 solve 判错  → 记 fp；stability×0.6；cache 立即置 stale（下次强制重推）
连续两次 stale     → 从缓存移除，转回 recon
```

这一条把"我以为我会"变成结构上可检测的事件：**缓存命中 + 实做失败 = 假阳性**，而不是靠自评。

4.5 写入管线与分层上下文（形态照抄，判据自定）

写入四步（每次录入一道判定都走同一条路，保证可审计）：

1. **抽候选**：从一次录入里抽出考点 id（2–4）、方法 id（1–3）、模式、耗时、结果。
2. **近邻比对**：取同考点最近 k 条判定与当前缓存项，判断这次是*重复命中*、*推翻旧结论*还是*首次出现*。
3. **写事件**：追加一行 jsonl（只追加，不改历史）；若是"推翻"，旧缓存项标 `state:"stale"` 并指向新事件，不物理删除。
4. **更新投影**：重算该考点/该方法的掌握、到期、缓存三组派生值，写回 `state.json`。

分层上下文（借 MemGPT 的三层形状，但检索由系统触发、不交给模型自觉）：

层	内容	容量/触发
core	本周单元、当前方法卡、今日两张纸的元信息	硬上限 ~2k 字，直接进提示
recall	全部判定的全文索引（可按考点/方法/日期过滤）	检索时取 top-k，带 as-of 时间
archival	已折叠的旧判定、历史错题原文	只按 id 取，不参与默认检索

三个"防蠢"约束：① 公式、定义、教材原文标 `protected`，改动需显式确认并留旧值；② 摘要按块失效——某考点变了，它的摘要与所属单元摘要是脏的；③ 反馈记三元组（原答，改后答，理由），只记对错会把"蒙对"当成会。

4.6 与 v1 的映射

v1 字段	v2 归属	说明
`state.nodes[id].hits/misses`	attempt 的聚合投影	保留，但改由 attempt 计算，不再单独写
`state.nodes[id].dueAt`	review(concept) 的派生值	算法换为 (stability, difficulty)
`state.daily[date][subject]`	attempt 的日聚合	用于"今天做了什么"，不参与掌握度
`state.flattened[]`	problem 的处置状态	"磨平"改为 attempt.outcome=hit 的连续计数
`content/method/*.json`	method 实体	补 `concepts{}` 权重与 `stability`

5. 指标与实验设计

指标	定义	用途	目标（首月）
Hit Rate	recall 模式 hit / 该考点 recall 次数	是否"想得起来"	≥ 0.65
Acc Rate	solve 判对 / solve 次数	是否"做得对"	≥ 0.55
FP Rate	(hit 且 solve 错) / hit	假阳性比例	逐月下降
Recon P50/P90	重推耗时中位数 / 90 分位	还原速度	同章下降 20%
Compression	claim 字数 / steps 字数	是否真的压过	≤ 0.25
Due Adherence	当天完成 due / 当天 due	调度是否可执行	≥ 0.7

5.1 三段式验证（不需要新数据）

1. **回放**：用已有 `events-*.jsonl` 重建，比较 v1 与 v2 对同一天的"该复习什么"的差异；差异必须能解释。
2. **消融**：去掉缓存层 / 去掉方法层 / 改 top-k=全部，看 FP Rate 与 Recon 时间的变化。
3. **前瞻**：连续 7 天按新调度执行，记录 Due Adherence 与 FP；不达标就回退参数，不改结构。

不做：A/B 分班、题库规模扩张、以刷题量作为指标。单用户系统里这些只会制造噪声。

6. 实施路线

步	交付	验证	依赖
S1	schema + 迁移脚本（v1 事件 → v2 实体）	回放 100% 可重建；删投影可恢复	无
S2	`POST /neuroloop/attempt`（写 attempt）与 `GET /neuroloop/decode?problem=`（top-k 检索）	host 测试新增 ≥ 10 条；错误码齐全	S1
S3	缓存层：ttl、stale、fp 检测；界面显示"缓存命中/重推"	构造一次"命中但错"→ 自动标 fp	S2
S4	调度换 FSRS 式；due 列表接进「今天」面板	Due Adherence 可算	S3
S5	方法层接入：录入方法卡时给出 concepts 权重，判分时可选方法	10 张卡全部有 concepts 与 stability	S2
S6	星图读 v2 投影（方法星层）	视觉验收（用户截图）	S5

排序理由：先让数据可信（S1–S3），再让调度有用（S4），最后才是视觉（S6）。反过来做等于给不可信的数据化妆。

7. 风险与反面清单

- **过度建模**：五个实体已接近单人系统的上限。再加"情绪/环境"只会让录入停摆。
- **假阳性定义过窄**：若长期没有 fp，先怀疑录入太少，而不是庆祝。
- **参数不可信**：FSRS 类参数需要足够日志；首月一律标 `calibrated:false`，用保守默认值。
- **方法卡膨胀**：10 张够用；每加一张必须能说出"它挡掉了哪类错"。
- **视觉先行**：星图是读投影的，不是真源。任何"看起来对"都不能替代 attempt 记录。

- **不可回退**：每次结构变更必须留下回放脚本，否则半年后无法解释历史数据。

8. 需要你拍板的四件事

问题	选项	我的建议
先做哪层	A 先结构（S1–S3）· B 先界面（S6）· C 先内容（补方法卡）	A：数据不可信时，界面越好看越误导
是否引入"方法"评分	A 每题必须选一个方法 · B 可选 · C 不记	B：强制会让人敷衍选择，不记则失去迁移证据
缓存命中怎么算对	A 只要 recall=hit 就算 · B 需 solve 也正确才计入 stable	B：这正是假阳性的定义来源
录入成本上限	A 每题 ≤60 秒 · B ≤30 秒 · C 不限	B：超过 30 秒的录入，三天后必然停摆

9. 参考文献

1. Corbett, A. T., & Anderson, J. R. (1995). Knowledge tracing: Modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4, 253–278. doi:10.1007/BF01099821
2. Doignon, J.-P., & Falmagne, J.-C. (1985). Spaces for the assessment of knowledge. *International Journal of Man-Machine Studies*, 23(2), 175–196. doi:10.1016/S0020-7373(85)80031-6
3. Falmagne, J.-C., Cosyn, E., Doignon, J.-P., & Thiery, N. (2006). The assessment of knowledge, in theory and in practice. *Formal Concept Analysis (ICFCA)*. doi:10.1007/11671404_4
4. Tatsuoka, K. K. (1983). Rule space: An approach for dealing with misconceptions based on item response theory. *Journal of Educational Measurement*, 20(4), 345–354. doi:10.1111/j.1745-3984.1983.tb00212.x
5. de la Torre, J. (2011). The generalized DINA model framework. *Psychometrika*, 76, 179–199. doi:10.1007/s11336-011-9207-7
6. Pelánek, R. (2016). Applications of the Elo rating system in adaptive educational systems. *Computers & Education*, 98, 169–179. doi:10.1016/j.compedu.2016.03.017
7. Piech, C., et al. (2015). Deep knowledge tracing. *NeurIPS*. arXiv:1506.02636
8. Zhang, J., Shi, X., King, I., & Yeung, D.-Y. (2017). Dynamic key-value memory networks for knowledge tracing. *WWW*. arXiv:1611.08108
9. Pandey, S., & Karypis, G. (2019). A self-attentive model for knowledge tracing. *EDM*. arXiv:1907.06837
10. Ghosh, A., Heffernan, N., & Lan, A. (2020). Context-aware attentive knowledge tracing. *KDD*. arXiv:2007.12324
11. Liu, Z., et al. (2022). pyKT: A Python library to benchmark deep learning based knowledge tracing models. *NeurIPS Datasets & Benchmarks*. arXiv:2206.11460 · github.com/pykt-team/pykt-toolkit
12. Anderson, J. R., Corbett, A. T., Koedinger, K. R., & Pelletier, R. (1995). Cognitive tutors: Lessons learned. *Journal of the Learning Sciences*, 4(2), 167–207. doi:10.1207/s15327809jls0402_2
13. Koedinger, K. R., Corbett, A. T., & Perfetti, C. (2012). The Knowledge-Learning-Instruction framework. *Cognitive Science*, 36(5), 757–798. doi:10.1111/j.1551-6709.2012.01245.x
14. Wozniak, P. A. (1987). Optimization of learning (Master's thesis, Poznań University of Technology). SM-2 算法原文：super-memory.com/english/ol/sm2.htm
15. Ye, J., Su, J., & Cao, Y. (2022). A stochastic shortest path algorithm for optimizing spaced repetition scheduling. *KDD*. doi:10.1145/3534678.3539081 · github.com/open-spaced-repetition/fsrs4anki
16. Settles, B., & Meeder, B. (2016). A trainable spaced repetition model for language learning. *ACL*, 1848–1858. aclanthology.org/P16-1174
17. Ebisu: Bayesian spaced repetition（实现与文档，未找到同行评议论文）github.com/fasiha/ebisu

18. DeepSeek-AI (2024). DeepSeek-V2: A strong, economical, and efficient mixture-of-experts language model. arXiv:2405.04434（MLA）
19. Kwon, W., et al. (2023). Efficient memory management for large language model serving with PagedAttention. *SOSP*. arXiv:2309.06180（KV cache 分页）
20. DeepSeek-AI (2025). Native Sparse Attention: Hardware-aligned and natively trainable sparse attention. arXiv:2502.11089
21. DeepSeek-AI (2024). DeepSeek-V3 technical report. arXiv:2412.19437（MoE 稀疏激活）
22. Ouyang, L., et al. (2022). Training language models to follow instructions with human feedback. arXiv:2203.02155（RLHF）
23. Rafailov, R., et al. (2023). Direct preference optimization: Your language model is secretly a reward model. arXiv:2305.18290
24. Kirkpatrick, J., et al. (2017). Overcoming catastrophic forgetting in neural networks. *PNAS*, 114(13), 3521–3526. arXiv:1612.00796 · doi:10.1073/pnas.1611835114（EWC）
25. Packer, C., et al. (2023). MemGPT: Towards LLMs as operating systems. arXiv:2310.08560
26. Rasmussen, P., et al. (2025). Zep: A temporal knowledge graph architecture for agent memory. arXiv:2501.13956
27. Chhikara, P., et al. (2025). Mem0: Building production-ready AI agents with scalable long-term memory. arXiv:2504.19413
28. Beltagy, I., Peters, M. E., & Cohan, A. (2020). Longformer: The long-document transformer. arXiv:2004.05150
29. Zaheer, M., et al. (2020). Big Bird: Transformers for longer sequences. *NeurIPS*. arXiv:2007.14062
30. Zhang, Z., et al. (2023). H2O: Heavy-hitter oracle for efficient generative inference of LLMs. arXiv:2306.14048（KV 淘汰）
31. Xiao, G., et al. (2023). Efficient streaming language models with attention sinks. arXiv:2309.17453（StreamingLLM，保开头高频）
32. Xu, W., et al. (2025). A-MEM: Agentic memory for LLM agents. arXiv:2502.12110
33. Gutiérrez, B. J., et al. (2025). From RAG to memory: Non-parametric continual learning (HippoRAG 2). arXiv:2502.14802
34. HippoRAG: Neurobiologically inspired long-term memory for large language models (2024). arXiv:2405.14831
35. Edge, D., et al. (2024). From local to global: A graph RAG approach to query-focused summarization. arXiv:2404.16130（GraphRAG）